BDD MULTIDIMENSIONALES

PRUEBA 2do BIMESTRE

Chantal Morales 2020/08/18

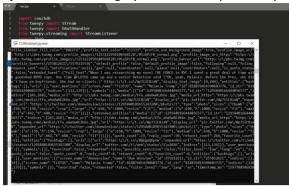
Tweets de New York a CouchDB
 Primero buscamos las coordenadas de NYC en Bounding Box



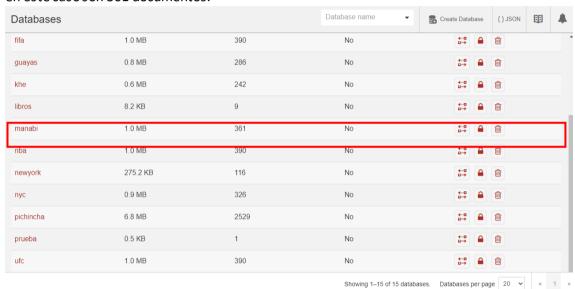
Escribimos el Código de extracción de tweets que es el archivo llamado "nyc.py" y ponemos las coordenadas extraídas para que filtre por geolocalización para obtener la primera base de datos de New York

```
nvc.pv
             "174Qtm7NRcByUC8f1RUpAgLfn"
     ckey
     csecret = "Dpbw43cRn86o2Di0YHYG9ZtCam1nHw2pcgnh670NZn4Mf0mahqatoken = "1574277428-7ANeKTU7WsNu7Vn7kh2XPigUGIjXuHn043GGRGH"
                 "Dpbw43cRn8Go2Di0YHYG9ZtCam1nHw2pcgnh670NZn4Mf0mahq"
      asecret = "K9nzrVDbEAuJ6Beeiubri0w9EAZ019VUrPFJ0drrLGg28"
      class listener(StreamListener):
          def on_data(self, data):
    dictTweet = json.loads(data)
                    dictTweet["_id"] = str(dictTweet['id'])
                    doc = db.save(dictTweet)
print ("SAVED" + str(doc) +"=>" + str(data))
                    print ("Already exists")
          def on_error(self, status):
    print (status)
      auth = OAuthHandler(ckey, csecret)
      auth.set_access_token(atoken, asecret)
      twitterStream = Stream(auth, listener())
                couchdb.Server('http://chantal:12345@localhost:5984/') #('http://115.146.93.184:5984/')
      server
          db
                server.create('newyork')
42
43
           db
              = server['newyork']
      twitterStream.filter(locations=[-79.76,40.48,-71.8,45.02])
```

Ejecutamos el código y verificamos que se haya creado la BDD en couchDB



La BDD "newyork" es la base donde se recolectaron todos los tweets podemos ver que en este caso son 361 documentos.

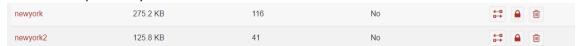


Comentamos la línea de filtro por geolocalización y activamos el filtro por palabras para la BDD que será utilizada como réplica objetivo en este caso se llamará "newyork2"

```
"''=======couchdb'========:''
server = couchdb.Server('http://chantal:12345@localhost:5984/') #('http://115.146.93.184:5984/')
try:
    db = server.create('newyork2')
except:
    db = server['newyork2']

"''===========LOCATIONS=========='''
#twitterStream.filter(locations=[-79.76,40.48,-71.8,45.02])
twitterStream.filter(track=['NYC'])
```

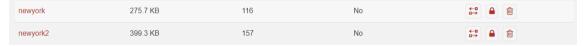
Verificamos que se haya creado en couchDB



Configuramos la réplica con las BDD (newyork y newyork2) generadas con los tweets. Para ello en Source seleccionamos la BDD desde la cual vamos a mandar los datos en este caso es newyork, tenemos que poner el usuario y password con el que accedemos a couchDB.

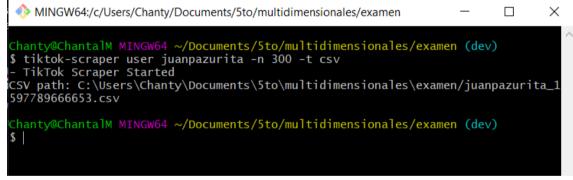
Job	Configuration									
Source										
			Type:	Local database	*					
			Name:	newyork	•					
	Authentication:		Username and password	•						
				chantal						
Target										
			Туре:	Existing local database	•					
			Name:	newyork2	.					
		Authe	entication:	Username and password	•					
http://localhost:5984/newyork http://				//localhost:5984/newyork2	Aug 18th, 5:23 pm	Continuous	Running	ے عر	Û	

Réplica hecha podemos ver que aumento el número de documentos en la base de datos objetivo en este caso newyork2.



2. TikTok

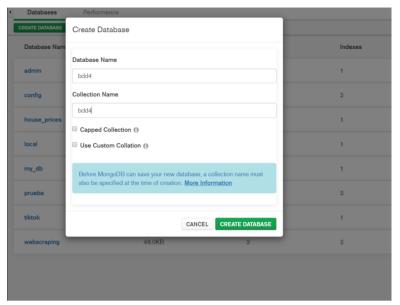
Para obtener datos de un usario de Tiktok en este caso será de Juapa Zurita escribimos esta línea de código con la cual llamamos la librería de tiktok scraper.



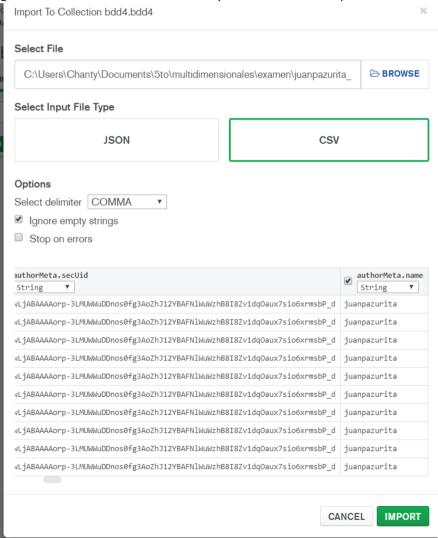
Se nos genera un archivo csv que contiene los datos del usuario, en la carpeta de la dirección en que ejecutamos el código.



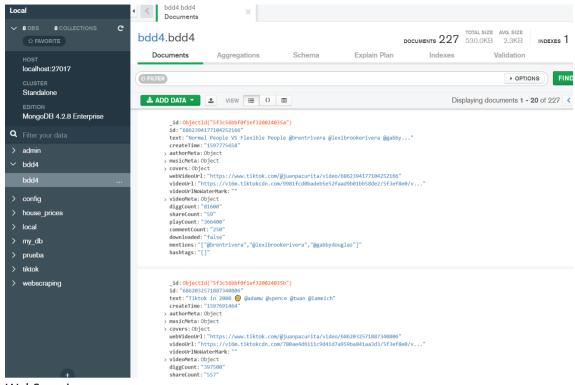
Una vez hecho esto vamos a MongoDB y creamos una base de datos y una colección donde vamos a guardar estos datos. En este caso será bdd4 y la colección bdd4.



Ingresamos a BDD4 y la colección creada e importamos el documento csv que se genero de nuestro usuario de tiktok y hacemos clic en importar.



Verificamos que se hayan insertado correctamente los documentos del archivo csv.

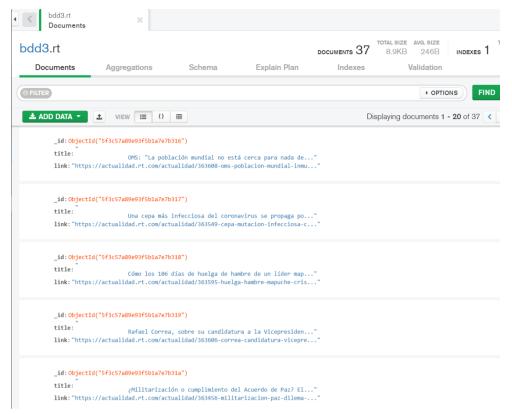


3. WebScraping

Para esto es necesario este script en el que utilizamos la librería de BeautifulSoup para web Scraping, especificamos la página de la que queremos obtener datos, la etiqueta y la clase y también definimos la BDD y la colección donde se guardaran estos datos en este caso bdd3 y la colección rt. (script en el archivo llamado webscraping.py)

```
webscraping.py
       requests
from bs4 import BeautifulSoup
# Import MongoClient from pymo
from pymongo import MongoClient
if __name__ == '__main__':
    # Instantiate a client to our MongoDB instance
db_client = MongoClient('mongodb://localhost:27017')
    bdd3 = db_client.bdd3
    rt = bdd3.rt
    response = requests.get("https://actualidad.rt.com")
soup = BeautifulSoup(response.content, "lxml")
    post titles = soup.find all("a", class ="Link-root Link-isFullCard")
    extracted = []
        r post_title in post_titles:
          extracted.append({
              'title' : post_title.text,
'link' : "https://actualidad.rt.com" + post_title['href']
    # Iterate over each post. If the link does not exist in the database, it's new! Add it. for post in extracted:
          if db_client.bdd3.rt.find_one({'link': post['link']}) is None:
              print("Found a new listing at the following url: ", post['link'])
               db_client.bdd3.rt.insert(post)
```

Verificamos que se hayan insertado los datos de la página en este caso de RT news.



4. Tweet Mongo

Para esto es necesario este script en el que utilizamos la librería de tweepy para obtener datos de twitter especificamos las palabras en el filtro de búsqueda de los que queremos obtener datos la BDD y la colección donde se guardaran estos datos en este caso bdd3 y la colección trump. (script en el archivo llamado tweetTrump.py). Es necesario para esto tener credenciales de twitter developer.

```
tweetTrump.py
     import pymongo
     from tweepy import Stream
from tweepy import OAuthHa
                    ort OAuthHandler
     from tweepy.streaming import StreamListener
     import json
    ckey = "1740tm7NRcByUC8f1RUpAgLfn"
    csecret = "Dpbw43cRn8Go2Di0YHYG9ZtCam1nHw2pcgnh67ONZn4Mf0mahq"
              "1574277428-7ANeKTU7WsNu7Vn7kh2XPigUGIjXuHn043GGRGH"
     atoken =
     asecret = "K9nzrVDbEAuJ6Beeiubri0w9EAZ019VUrPFJOdrrLGg28"
12
     class listener(StreamListener):
         def on_data(self, data):
             dictTweet = json.loads(data)
                 dictTweet["_id"] = str(dictTweet['id'])
                 doc = mycol.insert_one(dictTweet)
                 print("SAVED" + str(doc) + "=>" + str(data))
                 print("Already exists")
         def on_error(self, status):
             print(status)
    auth = OAuthHandler(ckey, csecret)
    auth.set access token(atoken, asecret)
     twitterStream = Stream(auth, listener())
     myclient = pymongo.MongoClient("mongodb://localhost:27017")
     mydb=myclient["bdd3"]
     mycol = mydb["trump"]
```

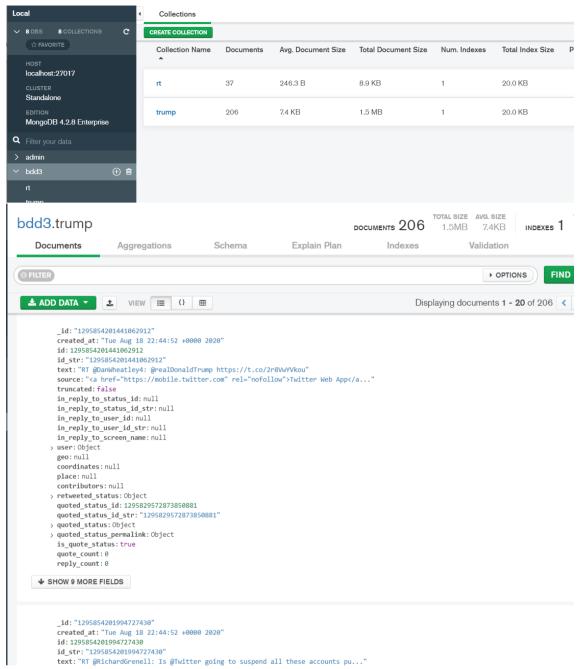
Ejecutamos el script.

C\Windows\py.exe

es\/themes\\theme1\/bg.png", "profile background_tile":false, "profile_link_color":"IDAIF2", "profile_sidebar_border_color
':"COBEED", "profile_sidebar_fill_color":"DDEEF6", "profile_text_color":"333333", "profile_use_background_images".true, "prof
le_image_url":"http:\/\/pbs.twimg.com\/profile_images\/686281894502207488\/SDPM2-AS_normal.jpg", "profile_image_url_http
':"https:\/\/pbs.twimg.com\/profile_images\/686281894502207488\/SDPM2-AS_normal.jpg", "profile_image_url_http
':"https:\/\/pbs.twimg.com\/profile_images\/686281894502207488\/SDPM2-AS_normal.jpg", "profile_banner_url":"https:\/\/pb
'twimg.com\/profile_banners\/680202093\/1452457526", "default_profile":true, "default_profile_image":false, "following":null,
'follow_request_sent":null, "notifications":null," proordinates*:null, "place":null, "contributors":null," rece"
':"Donald Trump is one of God\u2019s finest warriors.", "source":\u0093ca href=\"http:\/\/twitter.com\/download\/iphone\
rel=\u00e4\u00fanta\/nin-reply_to_user_id":null,\u00e4\u0093ca\u00e4\u0 C:\Windows\py.exe

П

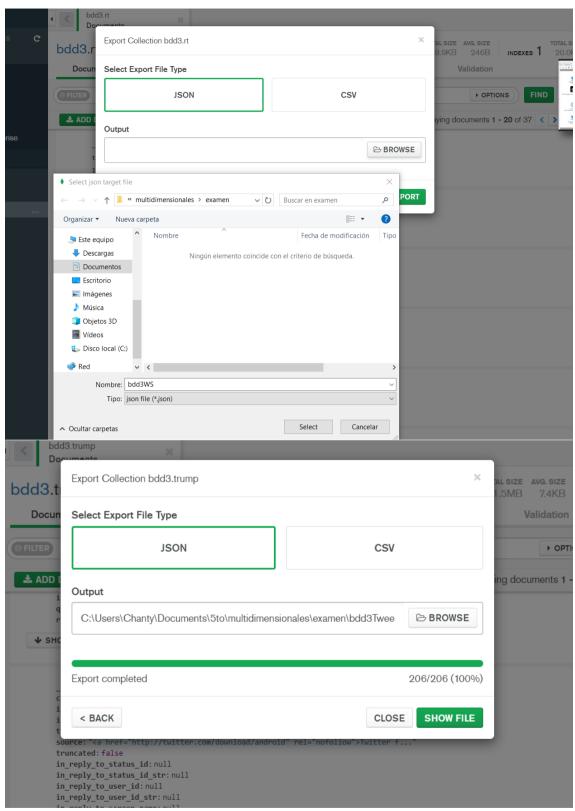
Verificamos que se haya creado la colección con los respectivos documentos que se recolectaron mientras estaba corriendo el proceso.



5. De la BDD3 a la BDD4

Para esto exportamos la colección en formato json, hacemos clic en exportar, seleccionamos la ruta de destino y el nombre con el cual se exportará el documento.

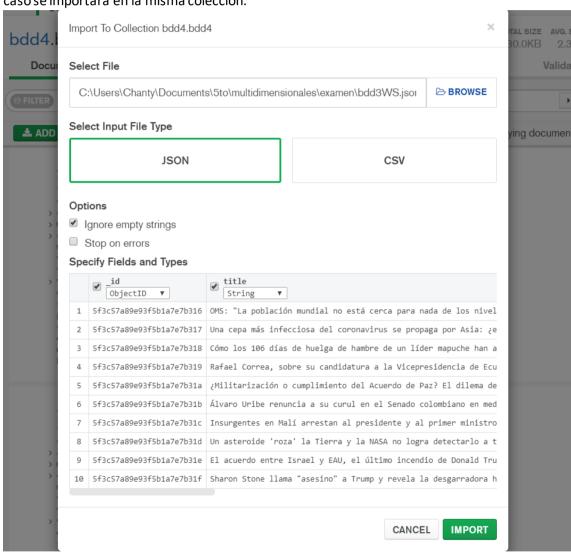


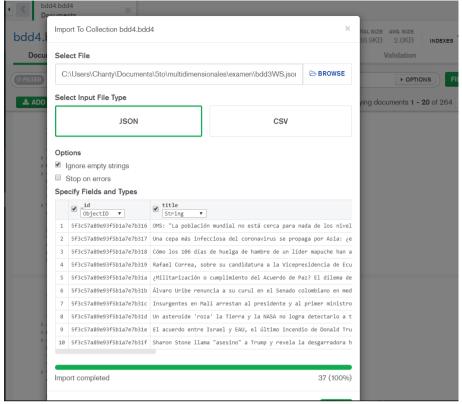


Hacemos clic en exportar, y verificamos que se haya generado el archivo .json de cada colección.

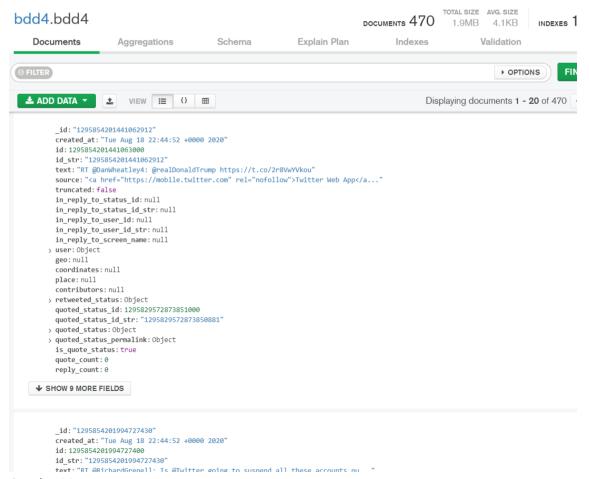


Una vez que obtenemos estos archivos importamos a la otra base de datos en este caso la bdd4. Para esto seleccionamos el archivo json que queremos importar en este caso se importará en la misma colección.





Verificamos que se hayan insertado correctamente los documentos de la bdd3.

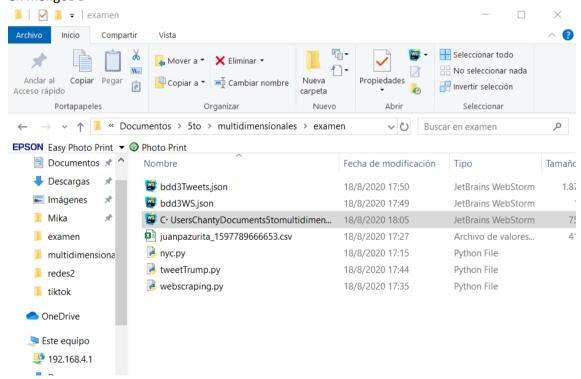


6. Couch a Mongo

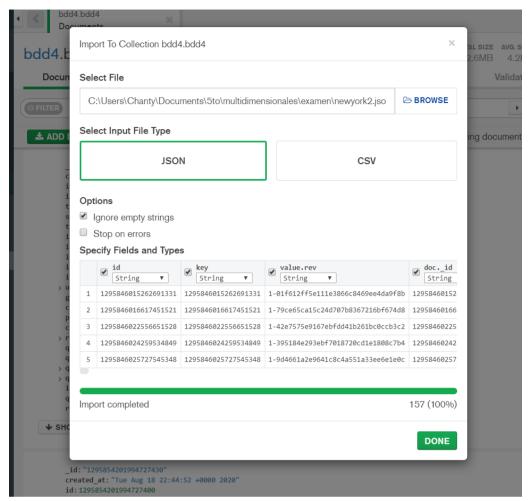
Para exportar un archivo tipo json desde CouchDB utilizamos este comando en el cual especificamos el nombre de la base de datos que queremos exportar, el usuario y password del usuario en couchDB.

```
NINGW64:/c/Users/Chanty/Documents/5to/multidimensionales/examen
                                                                                                            X
Chanty@ChantalM MINGW64 ~/Documents/5to/multidimensionales/examen (dev)
$ curl -X GET http://chantal:12345@127.0.0.1:5984/newyork2/_all_docs\?include_do
cs\=true_> C:\Users\Chanty\Documents\5to\multidimensionales\examen\newyork2.json
   % Total
                    % Received % Xferd
                                                  Average Speed
                                                                          Time
                                                                                       Time
                                                                                                             Current
                                                  Dload
                                                           Upload
                                                                          Total
                                                                                                    Left
                                                                                      Spent
                                                                                                            Speed
      752k
                        752k
                                    0
                                             0
                                                  11.1M
                                                                  0 --
Chanty@ChantalM MINGW64 ~/Documents/5to/multidimensionales/examen (dev)
```

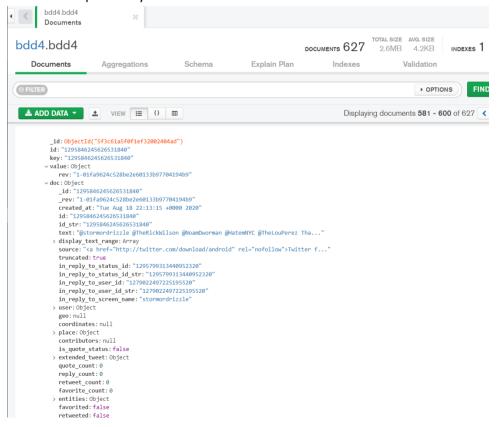
Verificamos que se nos haya creado el documento json en la carpeta destino Es necesario modificar el archivo json de cuchdb y lo adaptemos al formato que coge en mongoDB



Importamos este archivo json a la bdd4 y la colección con los datos en común. (archivo json de couchdb llamado newyork2.json)

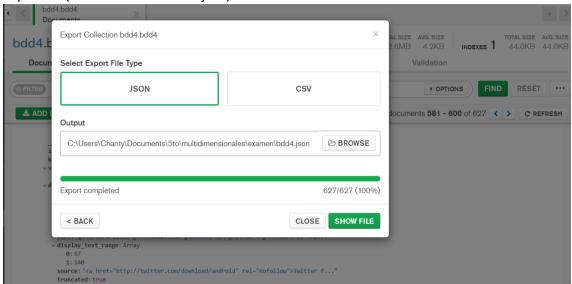


Verificamos que se hayan insertado correctamente los documentos.



7. Mongo a Atlas

Para subir los datos al cluster es necesario primero descargar un archivo tipo json que contenga los datos finales de los 4 ejercicios realizados, en este caso seleccionamos exportar en la bdd4 en tipo json, seleccionamos la carpeta destino y hacemos clic en exportar. (archivo llamado bdd4.json)

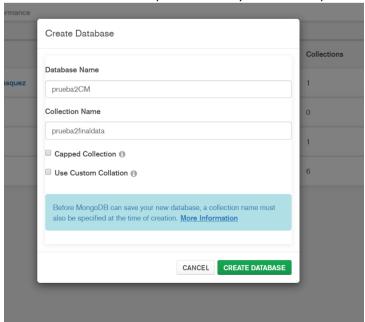


Ingresamos a nuestro cluster para esto tenemos que poner la cadena de conexión del mismo en este caso es:

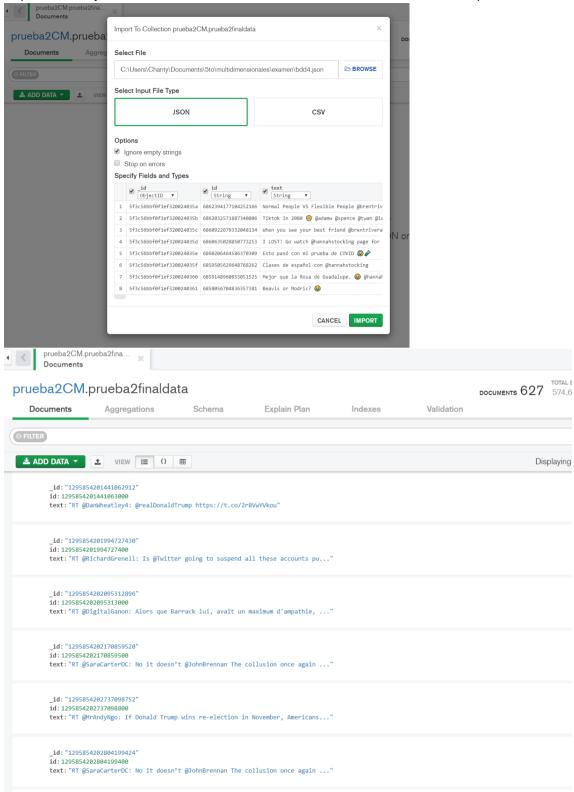
mongodb+srv://cmorales:12345@cluster0.suyhk.mongodb.net/test Una vez que accedemos al mismo creamos una base de datos donde importaremos el json obtenido anteriormente y su colección.



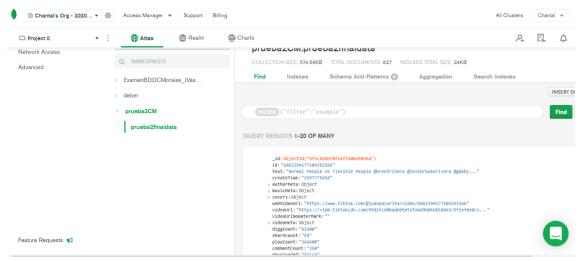
La bdd creada se llamará prueba2BCM y la colección pruebafinaldata



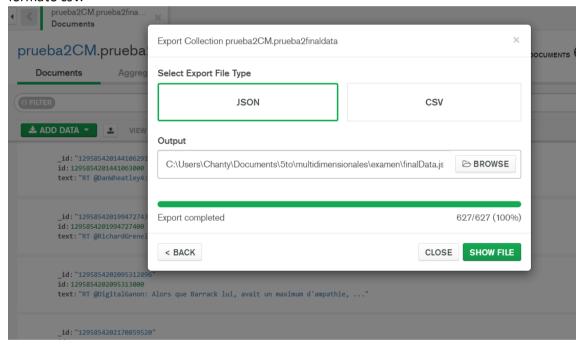
Importamos el json obtenido de la bdd4 como lo he realizado en los anteriores pasos.

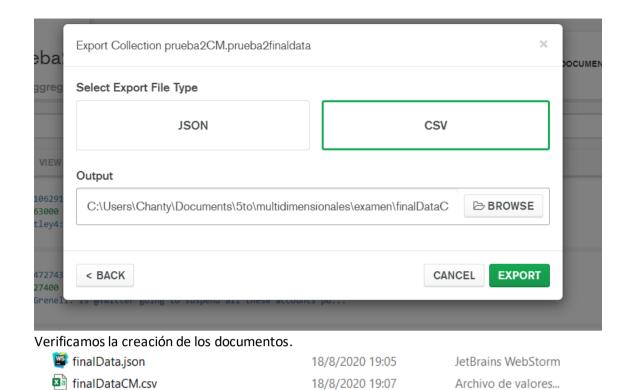


En la imagen a continuación, podemos ver la información desde el cluster en Atlas.



8. Finalmente, exportamos en formato json y formato csv la colección con los datos agrupado de las demás bdd que están en el cluster, para esto solo es necesario primero escoger formato json y poner el nombre del archivo, y de igual manera para el formato csv.





CADENA DE CONEXIÓN:

mongodb+srv://cmorales:12345@duster0.suyhk.mongodb.net/test